

Laboratorio 7: NLP y embeddings

Javier Valladares, 23045 · Ian Cumes, 23236

CC3092 - Deep Learning y Sistemas Inteligentes · 05 de octubre de 2026


1. Pipeline y exploración

WikiText-103 train: **29,443 artículos, 1,801,350 líneas y 86,951,330 tokens** después de normalizar. Validación: 184,480; test: 207,485. Artículos = encabezados de nivel uno; líneas = filas, incluidas vacías. Usamos un prefijo de 22,000,000 tokens (7,699 artículos iniciados), que deja **21,336,925 tokens conocidos**; no se usa validación/test WikiText para entrenar.

Normalización: NFKC y minúsculas; puntuación, guiones y apóstrofes separados; números literales; etiquetas y marcadores WikiText eliminados. Sin stopwords, stemming ni lematización. Mantener minúsculas y formas léxicas permite reutilizar GloVe; su tokenización no se supone idéntica, por lo que medimos OOV. Comparación con NLTK Treebank en 12 oraciones: nuestra función fragmenta *can't* en *can*, *t* y *Dr.* en *dr*; Treebank produce *ca*, *n't* y conserva abreviaturas/puntuación. También difieren en guiones, decimales y correos (detalle en notebook).

Zipf es aproximadamente válida: pendiente -1.10 entre rangos 100-10,000; no una ley exacta en las colas. Top 10 / 1,000 / 30,000 cubre **24.25% / 64.77% / 95.69%** de los tokens de train completo.

min_count	Vocabulario (22M)	Tokens OOV (%)
1	234,363	0.00
5	82,265	1.14
20	38,569	3.01
50	22,345	5.31



2. Investigación breve

Embedding(V,d) devuelve filas por ID; **padding_idx** excluye padding de gradientes; **sparse** dispersa gradientes (pesos densos). **from_pretrained(..., freeze)** controla actualización. **EmbeddingBag** agrega documentos por offsets iniciales con mean/sum/max; max no admite gradiente disperso. CBOW predice centro desde contexto; skip-gram predice contexto desde centro. SGNS usa W de entrada y W' de salida, conserva W . Word2Vec es predictivo; GloVe ajusta conteos globales. Investigación ampliada y parámetros gensim en notebook y docs/investigacion.md.


3. Entrenamiento propio y referencia

SGNS propio en PyTorch: dos tablas, negativos con distribución $f^{0.75}$, pérdida logística estable y SGD por minibatch (suma de pérdidas). CPU M1 Pro, 4 hilos, 16 GB; GPU no utilizada (pico GPU 0). Todas las iteraciones: 3 epochs, min_count=20, sample= 10^{-5} , batch=1,024, LR lineal 0.025 a 0.001, semilla 23045. Se mantiene un vocabulario fijo para las ablaciones; algunas palabras quedan sin entrenar en los prefijos pequeños.


Iteración	Tokens M	d / w / k	Epoch*	WS353	Acc. (%)	Tiempo min
d100_k5	21.34	100 / 2 / 5	3	0.562	15.3	3.7
d100_n100	21.34	100 / 2 / 3	3	0.551	11.8	3.4
d100_n25	5.33	100 / 2 / 3	3	0.138	0.8	0.8
d100_n50	10.67	100 / 2 / 3	3	0.376	2.4	1.6
d100_w5	21.34	100 / 5 / 3	3	0.650	23.4	7.6
d300_n100	21.34	300 / 2 / 3	3	0.539	10.9	4.9
d50_n100	21.34	50 / 2 / 3	3	0.546	11.5	2.8

Selección: Spearman WS353 + accuracy total, con candidatos idénticos; SimLex queda reservado. Modelo principal **d100_w5**, epoch 3; sólo son elegibles modelos con $\geq 20M$ tokens conocidos. Mejor 100d: d100_w5. Se guardan vecinos de king, france, computer, good, january y run en cada epoch.

$p(\text{conservar}) = \min(1, (\sqrt{f/t} + 1)t/f)$. Descarte observado de the/of/and: **98.83% / 98.23% / 98.14%**. Reduce dominio de palabras funcionales y costo. Epoch seleccionada: 205,575,606 pares antes, 64,740,032 después, ventana 5; no cruzan líneas.



Gensim usa exactamente corpus y vocabulario del modelo principal y dimensión/ventana/negativos/subsampling/LR equivalentes; total 0.7 min. Difieren actualizaciones por pares con 4 workers y minibatches de PyTorch, así como orden/muestras aleatorias; no se esperan pesos iguales. Una pérdida menor no asegura más analogías: el objetivo local no optimiza ese benchmark. Con k distinto las pérdidas ni siquiera tienen la misma escala.



4. Aritmética vectorial, benchmark y paralelismo


3CosAdd: $q = \text{norm}(-\text{norm}(a) + \text{norm}(b) + \text{norm}(c))$, ranking por coseno y exclusión de a,b,c; coincide con most_similar en todas las consultas cubiertas. 3CosMul usa cosenos trasladados a [0,1], con epsilon 10^{-6} . Benchmark: **30,000 candidatos compartidos, 12,154/19,544 preguntas (62.2%)**; las preguntas son las mismas en los tres modelos. Resultados por categoría, Add / Mul en %:

Categoría	n	SGNS	gensim	GloVe
capital-common-countries	462	26.4 / 26.2	25.8 / 24.9	93.9 / 92.0
capital-world	1206	20.3 / 17.5	18.0 / 16.7	89.3 / 87.0
currency	108	0.9 / 0.0	0.9 / 0.0	4.6 / 4.6
city-in-state	1687	10.8 / 10.1	9.1 / 8.5	30.6 / 27.2
family	342	24.0 / 22.8	19.3 / 17.0	88.3 / 87.4
gram1-adjective-to-adverb	812	4.7 / 3.8	5.3 / 3.6	27.8 / 28.0
gram2-opposite	306	2.6 / 1.6	4.6 / 2.0	28.1 / 24.5
gram3-comparative	1260	17.5 / 16.1	20.8 / 17.5	80.4 / 77.9
gram4-superlative	702	11.1 / 11.1	11.5 / 10.1	61.3 / 61.7
gram5-present-participle	870	21.4 / 14.4	22.0 / 16.2	73.2 / 72.2
gram6-nationality-adjective	1299	59.9 / 54.7	53.1 / 47.5	97.4 / 95.8
gram7-past-tense	1406	38.1 / 29.7	33.4 / 25.6	57.5 / 55.0
gram8-plural	992	23.7 / 19.3	29.4 / 22.7	79.2 / 75.4
gram9-plural-verbs	702	19.2 / 15.5	17.5 / 14.1	57.8 / 59.8

21 analogías propias en 7 tipos (género, capital, gentilicio, comparativo, superlativo, pasado y plural). Notebook/CSV incluyen top-5 con similitudes, rango y coseno de la respuesta y ranking sin exclusión para cada modelo. Ejemplo man:woman :: king:queen:

Modelo	Top-1 excluyendo	Rango queen	Cos(queen,q)	Top-1 sin excluir	Paralelismo medio
SGNS	consort	28	0.639	king	0.392
gensim	marriage	39	0.607	king	0.381
GloVe	queen	1	0.770	king	0.619

Para suplir la sección 5.3 ausente, medimos $\cos(v_b - v_a, v_d - v_c)$ y residuo relativo en vectores crudos. El paralelismo no implica igual magnitud; el ranking tampoco es igualdad algebraica. Sin exclusión, una palabra de consulta puede dominar: la analogía se interpreta como proximidad aproximada, no como igualdad.




t-SNE de 500 palabras normalizadas; grupos definidos con países, números y WordNet (animales, verbos, artefactos). Hay zonas temáticas y solapamientos; la proyección local y la polisemia impiden interpretar distancias 2D como prueba de relaciones exactas.

5. Pipeline end-to-end: AG News


Split estratificado: 108,000 train / 12,000 validación; 7,600 test oficial. Misma tokenización. EmbeddingBag(mean) + MLP 128/ReLU/dropout 0.2/4 salidas; 10 epochs, batch 512, Adam para MLP y SparseAdam para tabla (LR 0.003). Se elige epoch y variante por F1 macro de validación; después se infiere una vez en test por ganador y fracción. La curva requiere modelos separados por fracción. Gensim se añade como control downstream. Dimensión: la de cada fuente; random usa la dimensión SGNS.

Modelo / variante	Acc val	P val	R val	F1 val	F1 test	Total / entrenables	Min
TFIDF	90.8	90.8	90.8	90.8	91.1	0.16M / 0.16M	0.1
random_FT	91.3	91.4	91.3	91.3	91.7	4.26M / 4.26M	0.3
SGNS_frozen	87.8	87.8	87.8	87.8	-	4.26M / 0.01M	0.1
SGNS_FT	90.6	90.7	90.6	90.6	91.1	4.26M / 4.26M	0.3
gensim_frozen	87.6	87.6	87.6	87.5	-	4.26M / 0.01M	0.1
gensim_FT	90.6	90.7	90.6	90.6	91.2	4.26M / 4.26M	0.3
GloVe_frozen	89.9	90.1	89.9	89.9	-	4.26M / 0.01M	0.1
GloVe_FT	91.5	91.6	91.5	91.5	91.8	4.26M / 4.26M	0.3

TF-IDF + regresión logística: unigramas, min_df=2, sublinear_tf, hasta 60k atributos, C=4; seis bloques de diez pasos L-BFGS con warm_start. Sus curvas muestran entropía cruzada sin regularización, no epochs de SGD. El test se usa sólo con las variantes ganadoras (guion = no evaluada).



Matrices con filas reales y columnas predichas; W=World, S=Sports, B=Business, T=Sci/Tech. La pérdida del promedio de embeddings elimina orden; noticias con términos compartidos entre Business y Sci/Tech pueden confundirse.



6. Comparación final y discusión

Métrica	SGNS	gensim	GloVe
Tokens / vocabulario / d	21.34M / 38,569 / 100	21.34M / 38,569 / 100	6,000M / 400,000 / 100
Entrenamiento / hardware	7.6 min / M1 Pro CPU	0.7 min / M1 Pro CPU	Tiempo y hardware del 100d: N/D [4]
3CosAdd sem / sint / total (%)	16.6 / 26.5 / 23.4	14.6 / 25.9 / 22.4	61.4 / 67.8 / 65.8
3CosMul sem / sint / total (%)	15.3 / 22.4 / 20.2	13.6 / 21.2 / 18.8	58.8 / 66.2 / 63.9
Spearman WS353 / SimLex999	0.650 / 0.270	0.638 / 0.271	0.533 / 0.298
Cobertura WS353 / SimLex (%)	97.5 / 98.4	97.5 / 98.4	100.0 / 100.0
Coseno medio de diferencias	0.392	0.381	0.619
AG News OOV train / test (%)	5.36 / 5.38	5.36 / 5.38	0.56 / 0.51
F1 macro test (100% / 1%)	0.911 / 0.843	0.912 / 0.848	0.918 / 0.864

Analogías individuales representativas: top-1 / rango de la respuesta esperada (ranking excluye la consulta). Top-5 y cosenos completos de las 21 consultas en el notebook.

Consulta (respuesta esperada)	SGNS top-1 / rango	gensim top-1 / rango	GloVe top-1 / rango
boy:girl :: brother:sister	wed / 787	fathered / 298	daughter / 6
france:paris :: germany:berlin	berlin / 1	berlin / 1	berlin / 1
france:french :: germany:german	german / 1	german / 1	german / 1
good:better :: bad:worse	deviated / 93	bigger / 16	worse / 1
small:smallest :: large:largest	size / 3	size / 252	largest / 1
run:ran :: swim:swam	swimming / 2	swimming / 2	swam / 1
cat:cats :: dog:dogs	foxes / 2	foxes / 8	dogs / 1

Aritmética: SGNS funciona mejor en gram6-nationality-adjective (59.9%) y peor en currency (0.9%). Semántica/sintaxis: 16.6% / 26.5%. Sus diferencias no son exactamente paralelas (coseno medio 0.392); queen no tiene por qué ser la vecina más cercana si se permiten palabras de consulta.

Escala y método: con 25/50/100% del corpus y 100d, accuracy total = 0.8 / 2.4 / 11.8%; GloVe = 65.8%. GloVe usa unas 281 veces más tokens. La tendencia apoya un efecto del corpus, pero no permite atribuir causalmente toda la brecha: cambian también dominio, objetivo, optimización y composición del prefijo.

Hiperparámetros: d=50: 11.5%; d=100: 11.8%; d=300: 10.9%. Más dimensiones no garantizan mejoras con tres epochs. Ventana pequeña aproxima contexto sintáctico; grande mezcla contexto temático, pero el efecto debe juzgarse por las categorías medidas. Aumentar negativos cambia el objetivo y el costo; su pérdida no es directamente comparable.

w=2,k=3: 11.8%; w=5,k=3: 23.4%; w=2,k=5: 15.3%. Gensim logra 22.4%; diferencias de actualización y orden explican parte de la discrepancia sin demostrar un error matemático.

Clasificación: mejor F1 de test al 100%: GloVe (0.918); random = 0.917, TF-IDF = 0.911. Para SGNS se elige SGNS_finetune; para GloVe, GloVe_finetune. Al 1%, random/SGNS/GloVe/TF-IDF = 0.771 / 0.843 / 0.864 / 0.838. Con pocas etiquetas, congelar reduce parámetros; fine-tuning adapta al dominio. La decisión se toma por validación, no por test.

Límites: una semilla, tres epochs, prefijos temáticamente sesgados y dimensiones potencialmente distintas; sin intervalos de confianza. La tabla de tarea se construye con todo train aun al usar pocas etiquetas. Los benchmarks de similitud tienen coberturas distintas; no deben confundirse con evaluación sobre exactamente los mismos pares. GloVe 100d: tiempo/hardware no inequívocos en las fuentes, por eso N/D. Gensim emitió avisos Cython; la auditoría comprobó vectores finitos (ver audit.json).

Fuentes: [1] PyTorch: Embedding/EmbeddingBag. [2] gensim Word2Vec/KeyedVectors. [3] Mikolov et al. (2013). [4] GloVe y Pennington et al. (2014). Datos: Salesforce/wikitext y fancyzhx/ag_news en Hugging Face.

Repositorio: <https://github.com/Javiervalladares1/Laboratorio-7-NLP-Embeddings>